


基于LLM的生物医学文献知识库建立 以转录因子调控为例

潘汪阅



- 生命科学的发展让人们认识到更多转录因子的潜在作用，但人工精确分析注释的数据库无法及时补充新发现的知识
- 以ZBTB10为例



TRRUST version 2
Transcriptional Regulatory Relationships
Unraveled by Sentence-based Text mining

About TRRUST Search Download

Sorry, ZBTB10 gene does not exist in our database.

You can find the symbol name for your query gene from below tables.
Tables for [human genes](#) and [mouse genes](#) included in TRRUST.

Species: ☒ Human ☐ Mouse

ZBTB10

****Examples****

提交 重置




ZBTB10

Advanced Create alert Create RSS User Guide

Save Email Send to Sort by: Best match Display options

MY CUSTOM FILTERS Edit custom filters

RESULTS BY YEAR



PUBLICATION DATE

☐ 1 year

68 results

Page 1 of 7

☐ **Zbtb10** transcription factor is crucial for murine cDC1 activation and cytokine secretion.
1
Cite Smita S, Ghosh A, Biswas VK, Ahad A, Podder S, Jha A, Sen K, Acha-Orbea H, Raghav SK. Eur J Immunol. 2021 May;51(5):1126-1142. doi: 10.1002/eji.202048933. Epub 2021 Mar 1. PMID: 33527393 [Free article.](#)
Mechanistic analysis revealed that **Zbtb10** KD enhanced the expression of NKRF (NF-kappaB repressing factor) leading to drastic suppression of NF-kappaB related genes. **Zbtb10** KD abrogated p65 and RelB nuclear translocation, thereby controlling the activation and matur ...

☐ **ZBTB10** as a potential prognosis biomarker and correlates with the tumor immune microenvironment in stomach adenocarcinoma.
2


LLM在文献提取上的应用潜力

- 在大规模语料库上的自监督预训练使得大语言模型能够学习人类语言中的深层统计规律，在专业文献的信息提取任务中表现出显著优势。
- 经严格生化分子方法确认的转录因子与其调控的靶基因多散布在碎片化的文献研究中，以非结构化的自然语言形式存在，描述方式不统一，往往依赖人工的识别和标准化

Prompt设计

- 提示词工程是一种大语言模型的后训练技术，通过提供合适提示词，提高通用模型在特定领域任务的表现。通过优化提示词，可以引导模型充分利用预训练知识，减少模型对监督数据的依赖。
- 一类为在大语言模型的输入层及隐藏层中构建可学习的提示向量，进行参数微调。更新近的一类则利用大语言模型本身的推理与反思能力，通过模型在任务上的表现自我修正优化提示词，在多轮的反馈优化中，实现不涉及模型参数的任务效果优化，例如 DSPy、GEPA、TextGrad等方法，这些先进的提示词工程技术提升了大语言模型的任务适应性

b Blackbox AI systems and backpropagation using natural language 'gradients'



文献下载

- 由于版权和爬虫限制等原因，大规模的文献下载一直有困难
- 初步的文献分析可以考虑从[PMC Open Access Subset – PMC](#)下载开放获取文献集开始
- 更进一步的获取需要构建完整工作流，会比较复杂
- 使用AI Agent也是一种可行的思路
mp.weixin.qq.com/s/KuVbmyYT1t47CojmVyf72g
- 有风险的方法是获得文献doi后，通过sci-hub等非正规途径获取

文献下载

- 初步分析也可以考虑使用Biopython. Entrez直接从pubmed拉取文献Abstract
- 文献检索

```
from Bio import Entrez

def search_tf_references(tf_list):
    results = {}

    Entrez.email = "2300012291@stu.pku.edu.cn" # 必须提供邮箱
    for tf in tf_list:
        # 构建搜索语句
        # aliases=get_protein_aliases(tf)
        alias_query = " OR ".join([f'"{alias}"[Title/Abstract]' for alias in alias_dict.get(tf, [])])
        query = f"transcription AND factor AND gene AND regulation AND {Cell} AND ({alias_query})"
        print(f"正在搜索: {tf}...")
        try:
            # 执行搜索
            handle = Entrez.esearch(db="pubmed", term=query, retmax=50)
            record = Entrez.read(handle)
            handle.close()
            pmids = record["IdList"]
            results[tf] = pmids
            print(f"找到 {len(pmids)} 篇文献")
            # 遵守 NCBI 频率限制
            time.sleep(0.5)
        except Exception as e:
            print(f"搜索 {tf} 时出错: {e}")

    return results
```

获取摘要

```
def fetch_abstracts(pmids):
    abstracts = {}

    for pmid in pmids:
        try:
            handle = Entrez.efetch(db="pubmed",
                                    id=pmid, rettype="abstract", retmode="text")
            abstract_text = handle.read()
            handle.close()
            abstracts[pmid] = abstract_text
            time.sleep(0.4) # 遵守 NCBI 频率限制
        except Exception as e:
            print(f"获取 PMID {pmid} 的摘要时出错: {e}")


    return abstracts
```

API

- 应用编程接口（application programming interface, API），定义了计算机之间或在计算机程序之间的连接，它是一种类型的软件接口，用来向软件的其他部分提供服务。它规定了能进行的调用（call）或请求（request）的种类，如何进行调用或发出请求，应使用的数据格式，应遵循的惯例等，又称应用程序接口。

API 申请

- 以Qwen为例（新用户有100w免费token） bailian.console.aliyun.com



在Python中使用API

- openai 是一个强大的 Python 库，用于与 OpenAI 的一系列模型和服务进行交互。
- openai 封装了所有 RESTful API 调用，让开发者能轻松地在自己的 Python 应用中集成强大的 AI 能力，例如自然语言处理、图像生成和语音识别等。
- openai 库也被各大模型服务提供商作为标准

```
pip install openai
```

```
pip install pdfplumber # 方便后续上传文献pdf
```

在Python中使用API

```
1 import os
2 from openai import OpenAI
3
4 client = OpenAI(
5     api_key="Your API Key Here",
6     base_url="https://dashscope.aliyuncs.com/compatible-mode/v1",
7 )
8
9
10 response = client.responses.create(
11     model="qwen3.6-plus",
12     input="9.9和9.11哪个大? ",
13     extra_body={
14         "enable_thinking": True # 启用思考模式
15     }
16 )
17
18 # 遍历输出项
19 for item in response.output:
20     if item.type == "reasoning":
21         # 打印推理过程摘要
22         print("【推理过程】")
23         for summary in item.summary:
24             print(summary.text[:500]) # 截取前500字符
25         print()
26     elif item.type == "message":
27         # 打印最终答案
28         print("【最终答案】")
29         print(item.content[0].text)
```

输入API

选择模型

【推理过程】 Here's a thinking process:

1. Analyze User Input:

- User asks: "9.9和9.11哪个大? " (Which is larger, 9.9 or 9.11?)
- This is a classic trick question that often confuses people because of version numbering vs. decimal numbering.
- In decimal numbers: 9.9 = 9.90, and 9.11 = 9.11. Comparing them as decimals: 9.90 > 9.11.
- In software versioning: 9.11 usually means version 9, release 11, which comes after version 9, release 9 (9.9). So 9.11 > 9.9 in versioning.
- The question doesn

【最终答案】 这取决于你比较的具体场景:

 如果是数学中的小数: 9.9 更大。

小数比较需逐位对齐: 9.9 = 9.90, 十分位上 9 > 1, 因此 9.9 > 9.11。

 如果是软件/产品版本号: 9.11 更大。

版本号中的 . 不是小数点, 而是层级分隔符。9.11 表示第 9 大版本的第 11 次迭代/子版本, 而 9.9 是第 9 次迭代, 因此 9.11 > 9.9。

 总结: 纯数字比大小看 9.9, 版本号比大小看 9.11。请根据你的实际使用场景判断。

使用API提取文献信息

- 1. 构建合适的Prompt, 比较方便的一个方式是, 向ai直接提问, 提供希望从文献中得到的信息, 例如转录因子, 靶基因, 细胞context, 调控类型实验方法, 置信度, 原始文献位置……; 提供希望的输出格式, 如json
- 2. 上传文献pdf
- 3. 批量调用API


```
def extract_text_from_pdf(pdf_path: Path) -> str:
    """本地提取PDF文本（避免API文件上传兼容性问题）"""
    text = ""
    with pdfplumber.open(str(pdf_path)) as pdf:
        for page in pdf.pages:
            page_text = page.extract_text()
            if page_text:
                text += page_text + "\n"
    return text.strip()
```

格式示例:

```
[
  {
    "transcription_factor": "TP53",
    "target_gene": "CDKN1A",
    "regulation_type": "activation",
    "evidence_type": "ChIP-seq, Luciferase reporter",
    "biological_context": "Human HCT116, DNA damage",
    "auxiliary_proteins": ["EP300", "CREBBP"],
    "confidence": "high",
    "location": "p.4, Fig.1C-D"
  }
]
```

评估文献提取结果

- 使用LLM提取的知识，缺少内部的评估标准，需要一个金标准 (gold standard) 对模型结果做评估
- 金标准可以来自于权威数据库或人工标注



具体分析上，可以分为两步

1. 关注整体指标：

Recall: 提的全不全

Precision: 提的准不准（幻觉）

2. 关注具体某篇文章为什么提错了
（这一步可以保存思考模型的思考过程做细致分析）

➡ 优化Prompt设计

构建数据库和网站

- 这里介绍的技术路径是通过高度成熟的sqlite数据库+flask Web微框架构建的，可以轻松通过vibe coding实现

什么是 SQLite? [SQLite – Python | 菜鸟教程](#)

SQLite是一个进程内的库，实现了自给自足的、无服务器的、零配置的、事务性的 SQL 数据库引擎。它是一个零配置的数据库，这意味着与其他数据库不一样，您不需要在系统中配置。

就像其他数据库，SQLite 引擎不是一个独立的进程，可以按应用程序需求进行静态或动态连接。SQLite 直接访问其存储文件。

SQLite3 可使用 sqlite3 模块与 Python 进行集成

什么是Flask? [Flask 教程 | 菜鸟教程](#)

Flask 是一个用 Python 编写的轻量级 Web 应用框架。Flask 基于 WSGI (Web Server Gateway Interface) 和 Jinja2 模板引擎，旨在帮助开发者快速、简便地创建 Web 应用。

Flask 被称为"微框架"，因为它使用简单的核心，用扩展增加其他功能。

转录因子调控关系查询与展示

这里展示从文献 PDF 中抽取并落库到 SQLite 的调控关系。你可以按转录因子、靶基因、来源 PDF、置信度和调控方向快速检索。

重建数据库

清空筛选

SQLite + Flask

文献数

8

关系总数

33

唯一 TF

4

唯一靶基因

23

转录因子

靶基因

来源 PDF

置信度

调控方向

如 TP53

如 CDKN1A

如 1.pdf

high / medium / low

activation / repression

重置条件

查询

当前结果：33 条， 每页 20 条展示

第 1 / 2 页

下一页

来源 PDF	转录因子	靶基因	调控方向	证据类型	生物背景	辅助蛋白	置信度	位置
1.pdf	ZBTB10	gastrin	repression	Literature citation	Human gastric cancer cells	["Sp1"]	low	p.2241, Introduction; p.2245, Discussion
1.pdf	Sp1	gastrin	activation	Literature citation	Human gastric cancer cells	["ZBTB10"]	low	p.2241, Introduction; p.2245,

来源 PDF	转录因子	靶基因	调控方向	证据类型	生物背景	辅助蛋白	置信度	位置
1.pdf	ZBTB10	gastrin	repression	Literature citation	Human gastric cancer cells	["Sp1"]	low	p.2241, Introduction; p.2245, Discussion
2.pdf	ZBTB10	Sp1	repression	Overexpression plasmid transfection, Western blot	Human MDA-MB-231 breast cancer cells	unknown	high	p.7, Fig.4B; p.8
2.pdf	ZBTB10	Sp3	repression	Overexpression plasmid transfection, Western blot	Human MDA-MB-231 breast cancer cells	unknown	high	p.7, Fig.4B; p.8
2.pdf	ZBTB10	Sp4	repression	Overexpression plasmid transfection, Western blot	Human MDA-MB-231 breast cancer cells	unknown	high	p.7, Fig.4B; p.8
3.pdf	ZBTB10	PKLR	repression	ChIP-seq, ChIP assay, GFP reporter assay, RT-qPCR, Western blot	Human prostate cancer cell lines (LNCaP, C4-2, PC3, LASCPC01), ADT conditions (CSS medium, MDV3100 treatment), clinical PCa tissues	unknown	high	Abstract, pp.2-4, Fig. 2, Fig. 3, Fig. 7F
4.pdf	ZBTB10	VEGFA	repression	Literature citation	Breast and ovarian cancer cells	unknown	low	Discussion, p.14
4.pdf	ZBTB10	FLT1	repression	Literature citation	Breast and ovarian cancer cells	unknown	low	Discussion, p.14
4.pdf	ZBTB10	KDR	repression	Literature citation	Breast and ovarian cancer cells	unknown	low	Discussion, p.14
4.pdf	ZBTB10	BIRC5	repression	Literature citation	Breast and ovarian cancer cells	unknown	low	Discussion, p.14
4.pdf	ZBTB10	SP1	repression	Literature citation	Breast and ovarian cancer cells	unknown	low	Discussion, p.14

更多可以做的

- Golden Standard的构建
- Prompt的自动反馈优化[Optimizing generative AI by backpropagating language model feedback | Nature](#)
- 上传Supplement File

可参考教程

- API使用：[首次调用千问API-大模型服务平台百炼\(Model Studio\)-阿里云帮助中心](#)；[主流大语言模型API参数详解 - 知乎](#)
- 类似的项目：[AI时代生物医学文献检索：从PubMed到LLM的智能 workflow 构建-CSDN博客](#)